

SCTEC - CICLO 2

PROJETO DO DESAFIO PRÁTICO DA TRILHA RÁPIDA DE INTELIGÊNCIA ARTIFICIAL

Autor: Luan Sarmento Orsi da Silva
email: luansarmento.luan@gmail.com

DESCRIÇÃO DO PROJETO

O objetivo do projeto é demonstrar a análise exploratória de uma base de dados relacionada à reservas de hotéis e treinar um modelo de inteligência artificial para prever o cancelamento de reservas, com o intuito de demonstrar os conhecimentos adquiridos na etapa Primeiros Passos do Ciclo 2 do projeto SCTEC e com base também no que foi ensinado na Trilha Rápida de Inteligência Artificial.

BIBLIOTECAS UTILIZADAS NO PROJETO

Manipulação de dados:

- Pandas
- Numpy

Visualização:

- Matplotlib (Pyplot)
- Seaborn

Machine Learning:

- Scikit-learn (train_test_split, RandomForestClassifier, accuracy_score, confusion_matrix, RocCurveDisplay, roc_auc_score)

ETAPAS DE DESENVOLVIMENTO

1. Importação e compreensão dos dados:

1. 1) Carregamento do dataset no ambiente Google Colab:

A fonte de dados utilizada neste projeto é a Hotel Booking Demand, localizada no link: <https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand>.

O arquivo do banco de dados encontra-se na pasta do projeto dentro do diretório "data". Seu caminho é "./data/hotel_bookings.csv".

No código, o arquivo é carregado e tem seus dados armazenados em um objeto do tipo DataFrame da biblioteca Pandas.

1. 2) Inspeção Inicial dos Dados:

É analisado primeiro o tamanho e uma pequena amostra do dataset, que possui 119.390 linhas com 32 colunas (não é possível apresentar todas as colunas na imagem abaixo sem prejudicar sua visualização):

Tamanho do dataset: 119390 linhas, 32 colunas

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	arrival_date_week_number	arrival_date_day_of_month	stays_in_weekend_nights
0	Resort Hotel	0	342	2015	July	27	1	0
1	Resort Hotel	0	737	2015	July	27	1	0
2	Resort Hotel	0	7	2015	July	27	1	0
3	Resort Hotel	0	13	2015	July	27	1	0
4	Resort Hotel	0	14	2015	July	27	1	0

5 rows x 32 columns

Em seguida é utilizada a função **df.info()** para visualizar os tipos de dados utilizados em cada coluna. Abaixo está um exemplo das informações de algumas das colunas:

#	Column	Non-Null	Count	Dtype
0	hotel	119390	non-null	object
1	is_canceled	119390	non-null	int64
2	lead_time	119390	non-null	int64
9	adults	119390	non-null	int64
10	children	119386	non-null	float64
11	babies	119390	non-null	int64
27	adr	119390	non-null	float64

Após isso, é feita a análise da presença de valores nulos, registros duplicados e alguns valores impossíveis como ADR negativo e ausência de hóspedes na reserva:

Nulos:

children	4
country	488
agent	16340
company	112593

Total de registros nulos: 129425

Registros duplicados: 31994

Registros com ADR abaixo de 0: 1

Registros sem hóspedes: 180

Observação: ADR significa *Average Daily Rate* (Tarifa Média Diária), um indicador de desempenho do setor hoteleiro que mede o rendimento médio diário por quarto ocupado em um determinado período de tempo. É um dado essencial na análise exploratória e no treinamento do modelo de IA no contexto deste projeto, já que as reservas com ADR mais alto podem influenciar a decisão dos hóspedes que optam pelo cancelamento.

Então são analisadas outras informações relevantes: os tipos de hotéis no dataset e a taxa geral de cancelamento:

Tipos de Hotéis: 'Resort Hotel' e 'City Hotel'

Taxa de cancelamento total: 37.0%

A coluna alvo (*target*) deste projeto será a “**is_canceled**”, que é do tipo int64 (número inteiro), podendo conter o valor **0** (reserva mantida) ou **1** (reserva cancelada).

Em seguida é feita a análise de possíveis valores extremos que possam enviesar o treinamento do modelo de IA, os chamados “*outliers*”. Com esse fim, é criado um gráfico do tipo Boxplot que mostra a distribuição de ADR por tipo de hotel (disponível na pasta “gráficos”, com o nome “**Grafico_boxplot_outliers.png**”). O boxplot resultante mostra a presença de poucos, mas extremos, outliers de ADR (chegando acima de 5000 €).

2. Tratamento e preparação dos dados:

É iniciado o tratamento dos dados removendo-se os outliers extremos identificados na etapa anterior. Após a aplicação de um filtro que remove os registros que têm o ADR acima de 1000 €. Apenas um registro foi removido.

Em seguida, são removidos os registros duplicados, pois estes podem causar enviesamento no treinamento do modelo de IA, prejudicando sua acurácia. Depois são tratados os nulos coluna por coluna com pelo seguinte método:

- Na coluna “**children**”, os nulos são preenchidos com 0 para indicar que não há crianças.
- Na coluna “**country**”, os nulos são preenchidos com “Unknown” (object), representando que esses registros são de países desconhecidos.
- Na coluna “**agent**”, os nulos são preenchidos com 0, ou seja, sem agentes.
- Na coluna “**company**”, os nulos são preenchidos com 0, dizendo que não havia empresa na reserva.

Após esse tratamento, foram removidas 31.994 linhas.


Em seguida, os valores impossíveis de ADR (1 linha) e de quantidade de hóspedes por reserva (166 linhas) são removidos.

Por fim, são verificadas as alterações no tamanho do dataset após todo o processo de tratamento dos dados. No total, 32.162 linhas foram removidas e o dataset agora possui 87.228 linhas com 32 colunas.

3. Análise Exploratória

Geração de visualizações gráficas para interpretação dos dados


Gráfico 1) Tipos de Hotéis



Este gráfico de barras compara a quantidade de reservas feitas por cada tipo de hotel.


O gráfico demonstra que City Hotels têm mais reservas do que Resort Hotels, sendo a distribuição de 53.273 reservas para City Hotel (61,07%) e 33.955 reservas em Resorts (38,93%).

Gráfico 2) Porcentagem de Cancelamento por Tipo de Hotel




Este gráfico de barras demonstra a porcentagem de reservas que foram canceladas em cada tipo de hotel. City Hotels têm 30,1% de suas reservas canceladas, enquanto os Resort Hotels têm 23,45% de cancelamento. Essa informação implica que os City Hotels possuem uma chance maior de cancelamento de suas reservas do que os Resort Hotels, uma informação que pode ser útil para o modelo de IA que será treinado.

Gráfico 3) Distribuição de ADR



O gráfico de histograma acima demonstra a distribuição de valores de ADR nos hotéis do dataset. Os dados da coluna 'adr' são filtrados para apresentar os valores entre 0 e 500 € na geração deste gráfico, já que a maioria dos registros se encontram nessa faixa e assim podemos nos concentrar onde há maior volume de dados. De acordo com o histograma criado, as médias de tarifas diárias se concentram, em sua maioria, entre 50 e 150 €, com a mediana sendo definida em 99 €.

Gráfico 4) Lead time por cancelamento



Este gráfico faz a comparação dos dados da coluna **“lead_time”** (tempo de antecedência da reserva) com os dados da coluna **“is_canceled”**. Ele demonstra que as reservas canceladas costumam ter um lead time maior. Reservas feitas com aproximadamente 120 dias de antecedência apresentam uma taxa de cancelamento mais alta, o que representa maior risco de perda financeira ao hotel. Isso mostra que os dados de **“lead_time”** são de grande importância para este projeto, já que há um padrão forte de antecedência longa nas reservas que são canceladas.

Em seguida, algumas colunas são criadas por combinações e derivações:

- **“total_noites”**: criada pela combinação de **“stays_in_weekend_nights”** com **“stays_in_week_nights”**, representando o total de noites que os hóspedes passaram em suas reservas;
- **“total_hospedes”**: criada pela combinação de **“adults”**, **“children”** e **“babies”**, representando o total de pessoas que se hospedaram em cada reserva;
- **“numero_mes”**: criada traduzindo os valores de **“arrival_date_month”** para a numeração dos meses do ano pela ordem deles, sendo de 1 a 12. Com os dados numéricos será muito melhor a exploração e o treinamento do modelo de IA, que dependerá de valores numéricos para fazer os cálculos estatísticos;

- **“alta_temporada”**: criada ao aplicar um filtro que verifica se cada registro na coluna **“numero_mes”** encontra-se entre 6 e 9, sendo registrado como 0 (baixa temporada) ou 1 (alta temporada). Com isso é possível analisar o comportamento dos hóspedes nos casos de reservas feitas em períodos tipicamente mais intensos do ano para o setor hoteleiro;
- **“antecedencia_longa”**: criada com o filtro que testa cada registro na coluna **“lead_time”** para saber se a antecedência é superior a 100 dias ou não, sendo 0 (não) ou 1 (sim). Este valor numérico que representa as antecedências maiores tornará possível a análise mais precisa do impacto do adiantamento das reservas no comportamento dos hóspedes, principalmente nos clientes que optaram pelo cancelamento;
- **“tem_crianças”**: criada a partir do teste em cada registro se a soma dos dados de quantidade de bebês (**“babies”**) com os da quantidade de crianças (**“children”**) é superior a 0, sendo então armazenado o valor 0 (não tem crianças) ou 1 (tem crianças);
- **“quarto_diferente”**: criada ao testar se os registros em **“reserved_room_type”** com os registros em **“assigned_room_type”**. Armazena um número inteiro que pode ser 0 (mesmo quarto) ou 1 (quarto diferente).

Então são criadas novas colunas como transformações numéricas (sendo números inteiros 0 ou 1, representando falso ou verdadeiro respectivamente) de variáveis categóricas para as seguintes colunas:

- **“deposit_type”**: criadas as colunas **“deposito_nao_reembolsavel”** e **“sem_deposito”**;
- **“market_segment”**: criadas as colunas **“canal_online_ta”** e **“canal_groups”**;
- **“customer_type”**: criada a coluna **“cliente_transient”**;
- **“hotel”**: criada a coluna **“is_city_hotel”**.

Por fim é criada uma coluna chamada **“taxa_cancel_anterior”**, que armazena um número entre 0 e 1 resultante da aplicação da fórmula abaixo para os registros de hóspedes que já fizeram uma ou mais reservas anteriormente:

$$T = p / (p + b)$$

onde:

T = Taxa de cancelamentos anteriores

p = número de cancelamentos anteriores

b = reservas anteriores não canceladas

Após a criação das colunas descritas, o dataset contém 87.228 linhas com 46 colunas.

Em seguida, são utilizadas algumas colunas na geração de um gráfico do tipo heatmap que demonstra a correlação entre informações importantes para a compreensão dos padrões de comportamentos dos hóspedes nos registros.

As colunas analisadas no gráfico de correlação são: **“adults”**, **“children”**, **“adr”**, **“is_repeated_guest”**, **“total_of_special_requests”**, **“is_canceled”**, **“total_noites”**, **“total_hospedes”**, **“alta_temporada”**, **“antecedencia_longa”**, **“tem_crianças”**, **“quarto_diferente”**, **“deposito_nao_reembolsavel”**, **“sem_deposito”**, **“canal_online_ta”**, **“canal_groups”**, **“cliente_transient”**, **“is_city_hotel”**, **“taxa_cancel_anterior”**, **“days_in_waiting_list”** e **“lead_time”**.

O gráfico gerado se encontra na pasta “graficos” dentro do diretório do projeto, com o nome **“Heatmap1_correlacao_entre_variaveis.png”**. A partir dele se obtém alguns insights importantes:

- **“lead_time”** tem correlação positiva (0.18) com **“is_canceled”**: quanto maior a antecedência da reserva, maior é a chance da reserva ser cancelada;
- **“total_of_special_requests”** tem correlação negativa (-0.12) com **“is_canceled”**: hóspedes que fazem pedidos especiais cancelam com menos frequência;
- **“is_repeated_guest”** tem correlação negativa (-0.09) com **“is_canceled”**: hóspedes frequentes no mesmo hotel tendem a cancelar menos as suas reservas;
- **“canal_online_ta”** possui correlação positiva (0.21) com **“is_canceled”**: clientes que vieram do segmento de marketing **“canal_online_ta”** tendem a cancelar com mais vezes;
- **“cliente_transient”** possui correlação positiva (0.13) com **“is_canceled”**: clientes do tipo **“Transient”** cancelam com mais frequência;
- **“deposito_nao_reembolsavel”** tem correlação positiva (0.16) com **“is_canceled”**: reservas feitas com depósito do tipo **“Non Refund”** têm um padrão de cancelamento mais recorrente.

4. Modelagem Preditiva

4. 1) Preparação dos dados

Agora são separadas 21 colunas *features* que serão utilizadas no treinamento do modelo de classificação deste projeto. As features selecionadas para isso são: **“lead_time”**, **“total_noites”**, **“total_hospedes”**, **“adr”**, **“numero_mes”**, **“alta_temporada”**, **“antecedencia_longa”**, **“is_repeated_guest”**, **“total_of_special_requests”**,

“tem_crianças”, “quarto_diferente”, “deposito_nao_reembolsavel”, “sem_deposito”, “canal_online_ta”, “canal_groups”, “cliente_transient”, “booking_changes”, “days_in_waiting_list”, “required_car_parking_spaces”, “is_city_hotel”, “taxa_cancel_anterior”, já que nos fornecem informações altamente relevantes quanto ao comportamento dos clientes no que diz respeito à frequência dos cancelamentos de suas reservas. A coluna “is_canceled” é definida como a coluna alvo (target) do modelo.

Em seguida é feita a divisão dos dados de treino e dados de teste:

Dados de treino: 69782 reservas (80.00%)

Dados de teste: 17446 reservas (20.00%)

Distribuição do target (“is_canceled”):

Mantidas: 63.220 (72.5%)


Canceladas: 24.008 (27.5%)

É estabelecido o *baseline*, ou seja, uma estimativa de predição básica que serve como um padrão mínimo para analisar a acurácia do modelo que será treinado a seguir.

Baseline: 72.48%

4. 2) Treinamento do modelo de classificação

Então é feito o treinamento do modelo de classificação **Random Forest**:



```
RandomForestClassifier
RandomForestClassifier(max_depth=25, min_samples_leaf=3, n_estimators=300,
                        n_jobs=-1, random_state=42)
```

Parâmetros utilizados:

- Número de árvores de classificação: 300;
- Profundidade máxima das árvores: 25;
- Mínimo de amostras para nó terminal (nó folha): 3;
- Quantidade de serviços paralelos: -1 (todos os processadores);
- Nível de aleatorização da amostragem: 42.

Abaixo uma pequena amostra de predição com o modelo Random Forest:

```
*** ===== 10 EXEMPLOS DE PREDIÇÃO (Random Forest) =====
```

lead_time	adr	total_noites	Real	Previsto	Acertou?
91	127.25	4	Cancelada	Mantida	False
0	136.00	1	Mantida	Mantida	True
59	102.56	3	Cancelada	Mantida	False
0	73.00	1	Mantida	Mantida	True
7	118.00	1	Mantida	Mantida	True
15	123.00	2	Mantida	Cancelada	False
157	127.00	3	Mantida	Mantida	True
0	0.00	0	Mantida	Mantida	True
22	127.67	3	Cancelada	Cancelada	True
187	105.30	2	Cancelada	Cancelada	True

Acertos: 7/10

4. 3) Avaliação do modelo

O desempenho do Random Forest é analisado com o relatório de classificação do Scikit-learn. As métricas analisadas foram a precisão (previsões corretas em geral), o recall (capacidade identificar corretamente os cancelamentos reais) e o F1-score (equilíbrio entre a precisão e o recall). Tendo em vista que o objetivo do modelo é prever os cancelamentos das reservas, o recall do alvo “**is_canceled**” é uma métrica de extrema importância, já que demonstra a capacidade do modelo de identificar os cancelamentos reais com antecedência.

Resultados da classificação:

Reservas mantidas:

- Precisão: 0.84
- Recall: 0.93
- F1-score: 0.88

Reservas canceladas:


- Precisão: 0.74
- Recall: 0.52
- F1-score: 0.61

AUC numérico do modelo: 0.86

Acurácia do modelo: 81.59%


É gerada uma matriz de confusão para medir o desempenho do Random Forest (o

arquivo da imagem do gráfico encontra-se na pasta “**graficos**” no diretório do projeto, com o nome “**Matriz_de_confusao.png**”):



Conforme o gráfico anterior demonstra, o modelo previu corretamente 11.752 casos de reservas mantidas e 2.482 de reservas canceladas, enquanto apresentou 852 falsos positivos e 2.320 falsos negativos. O modelo possui uma boa precisão em identificar reservas que serão mantidas (93% de acerto), mas não pode prever boa parte dos cancelamentos reais (48% de erro). De modo geral, o classificador possui um bom desempenho, mas precisa de melhorias em sua capacidade de antecipar os casos de cancelamento.

Em seguida é feita a análise da importância das features no classificador através do seguinte gráfico:



Os dados referentes à antecedência das reservas, às taxas médias diárias, pedidos especiais feitos pelos clientes e canal de marketing **“Online TA”** são os mais importantes no padrão de comportamento dos hóspedes. A coluna **“lead_time”** domina com 20% de importância nas previsões, seguido pela coluna **“adr”** com 13% e **“total_of_special_requests”** com 10%. Essas informações confirmam os insights obtidos durante a etapa de análise exploratória e pelos gráficos gerados nela. Por outro lado, colunas como **“days_in_waiting_list”**, **“is_repeated_guest”** e **“canal_groups”** tiveram muito menos importância no processo de classificação do modelo, indicando que esses fatores possivelmente não influenciam a decisão dos clientes de manter ou cancelar suas reservas.

CONCLUSÃO

Após a análise exploratória dos dados, a geração de visualizações gráficas e o emprego do modelo de classificação Random Forest, conclui-se que os fatores mais relevantes no padrão de comportamento dos hóspedes no dataset no que diz respeito ao cancelamento de suas reservas foram **“lead_time”**, **“adr”** e **“total_of_special_requests”**. O modelo atingiu 81,59% de acurácia, um desempenho superior ao baseline de 72,48%, o que demonstra a sua capacidade de identificar padrões determinantes no comportamento dos hóspedes que optam pelo cancelamento.